基于患者相似性分析的药物推荐深度学习模型研究*

吴佳伦[1] 张若楠[2] 康武林[3] 袁普卫[3]

[1](西安交通大学计算机科学与技术学院 西安 710049)

[2](西安交通大学图书馆 西安 710049)

[3](陕西中医药大学附属医院 咸阳 712046)

摘要:【**目的**】研究一种通过解析结构化时序医疗健康数据、分析患者相似性以准确预测药物组合的深度学习模型。【**方法**】通过两种注意力机制解析结构化时序数据以学习全面的患者表示,通过计算患者相似性丰富患者表示,最终将药物推荐问题转化为多标签学习问题。【**结果**】在MIMIC-III数据集上进行实验,相较于现有最优药物推荐模型,所提模型的DDI率降低了1.09个百分点,同时所提模型的Jaccard相似性、PRAUC和F1值分别提升了2.38、1.40和1.08个百分点。【**局限**】模型尚未融入生物医学等具有领域特色的先验知识;未深究数据本身存在的噪声及其在临床应用可能出现的问题。【**结论**】所提模型能够准确学习全面的患者表示,并提升药物推荐任务的安全性和准确性。

关键词: 药物推荐 电子健康记录 患者表示学习 深度学习

分类号: TP391 G35

DOI: 10.11925/infotech.2096-3467.2022.0535

引用本文: 吴佳伦, 张若楠, 康武林等. 基于患者相似性分析的药物推荐深度学习模型研究[J]. 数据分析与知识发现, 2023, 7(6): 148-160.(Wu Jialun, Zhang Ruonan, Kang Wulin,et al. Deep Learning Model of Drug Recommendation Based on Patient Similarity Analysis[J]. Data Analysis and Knowledge Discovery, 2023, 7(6): 148-160.)

1 引 言

近年来,随着医疗信息化的发展,医疗健康领域积累了大量与患者健康相关的电子健康记录(Electronic Health Records, EHRs)[1]。患者的结构化多变量时序数据,即在不同时间多次就诊形成的不同检验检查结果等结构化数据,因为其包含时序关系且涉及多个与健康相关的因素,是一种重要且在医疗领域广泛记录的数据类型。深度学习[2]是当前医疗多变量时序数据分析的主流方法,通过分析

通讯作者(Corresponding author):袁普卫(Yuan Puwei),ORCID:0000-0001-7916-8823,E-mail:spine_surgeon@163.com。

*本文系陕西省科技厅2021年重点研发计划高校联合重点项目(项目编号:2021GXLH-Z-095)、陕西省教育厅2021年度科研计划项目"服务地方专项"(项目编号:21JC010)和陕西省教育厅"骨退行性疾病中西医结合防治转化医学陕西省高校工程研究中心"项目(项目编号:陕教技办[2021]10号)的研究成果之一。

The work is supported by the 2021 Key R&D Plan of Shaanxi Provincial Department of Science and Technology "Joint Key Projects of Colleges and Universities"(Grant No. 2021GXLH-Z-095), the 2021 Shaanxi Provincial Department of Education Scientific Research Projects "Local Special Services"(Grant No. 21JC010), the Shaanxi Provincial Department of Education "Shaanxi University Engineering Research Center for the Prevention and Treatment of Osteodegenerative Diseases with Integrated Traditional Chinese and Western Medicine"(Grant No. 陕教技办[2021]10号).

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

与挖掘数据，能够建立预测模型，提高医疗效率，辅助医生临床决策[3-5]。其中，药物推荐，即预测用于治疗患者疾病的药物组合，是一项非常重要的任务，可以帮助临床医生开出安全有效的药物组合处方。

药物推荐首先要学习患者的健康状况表示，将患者复杂的健康数据压缩至低维空间中，从而进行药物组合预测。根据患者表示学习策略，药物组合推荐这一过程通常可以通过两种方式进行：基于实例的方法以及基于患者纵向病史的方法。虽然这些基于深度学习的方法在药物准确性和安全性等方面已经取得了不错的成效，但这些工作仍存在不足之处：首先，在学习患者表示时仅考虑患者的部分医疗信息（如诊断信息和手术信息），而忽略了一些患者的关键医疗信息（如历史用药信息），这样学习到的患者表示是不完整的；其次，仅从目标患者自身的历史医疗记录出发，而忽略了目标患者与其他患者之间的相似性。与医生为患者诊断病情和选择治疗方式类似，不同病例之间的相似性可以为患者的诊断和治疗提供强有力的参考。然而，如何通过患者纵向病史中的多变量时序数据进行患者疾病状态表示学习，以及如何定义并计算不同患者病史轨迹之间的相似性，成为在多变量时序医疗数据中利用患者相似性分析以推荐药物组合的两大挑战。

本文提出一种基于患者相似性分析的药物推荐深度学习模型——MedSim。该模型可以学习完整的患者表示，并通过检索具有相似性的患者序列推荐安全和准确的药物组合，以患者相似性为着手点进行药物推荐，以期实现更加安全和准确的精准医疗及个性化医疗。

2　相关研究

2.1　药物推荐

药物组合推荐对于患者的治疗至关重要[6-7]。如图 1 所示，通过访问患者的当前疾病状态以及历史医疗记录，有针对性地预测药物组合信息。

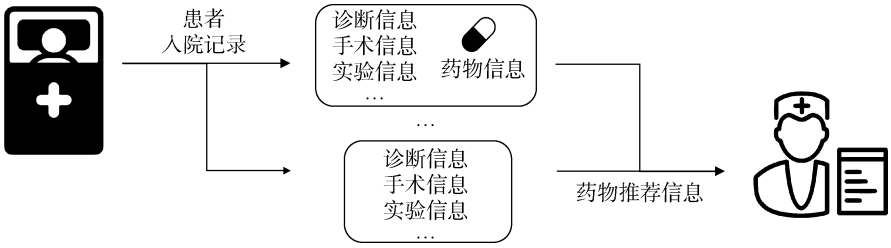


图 1　药物推荐任务定义

Fig.1　Task Definition of Drug Recommendation

根据患者表示学习策略，现有的药物推荐方法可分为基于实例的药物推荐和基于患者纵向病史的药物推荐两类。基于实例的药物推荐仅根据患者当前就诊信息学习患者表示。Zhang 等[8]提出一种具有注意机制的多实例多标签学习框架 LEAP，根据当前入院期间的临床事件预测药物组合。这种方法仅根据患者当前的入院信息进行预测，而没有考虑患者的纵向病史信息[8-9]。因此，采用这种方法，一名诊断出急性高血压的患者会得到与另一名患有慢性高血压的患者相同的治疗，这影响了药物组合推荐的安全性和有效性。由于这种方法无法捕捉患者真实的症状模式，最近的工作更多地关注于基于患者纵向病史的药物推荐，通过从患者纵向病史中捕获临床事件之间的依赖性学习患者表示[10-12]。Choi 等[13]提出的 RETAIN 模型采用反向时间注意力机制的两个基于循环神经网络的结构捕获时间依赖性，对患者纵向病史进行建模。Shang 等[14]提出的 GAMENet 模型利用存储单元对病人历史进行学习，利用图卷积神经网络对药物进行建模，为药物组合预测提供了参考。

这些方法将药物组合预测建模为多标签二分类问题[12-14]，或者序列决策问题。例如，Wang 等[15]提出了一个基于深度 Q-Learning 模型捕捉药物间相互作用。然而，上述模型只考虑了目标患者的单次就诊

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

信息(即最新的就诊信息),而忽略了患者的历史治疗记录。本文提出的MedSim模型分析了患者纵向病史数据,将药物组合推荐任务转换为一个多标签学习问题,并基于患者相似性分析推荐药物。

2.2 患者相似性分析

患者相似性分析通常是通过分析诊断记录、手术记录和药物组合等多类型的数据,选择与目标患者相似的患者群体。精确测量患者的相似性,为精准医疗提供更多的支持,如为当前病例选择相似的患者作为诊断和治疗的参考信息、确定某种疾病的亚组、设计治疗指南[16-17]等。例如,Zhang等[18]以Jaccard评分作为相似性指标以选择相似的患者,并使用所选择的患者推荐治疗高胆固醇的药物。

在多变量临床时间序列上计算患者相似性的方法一般可以分为两类。第一类是直接使用适当的时间序列测量相似性,如动态时间扭曲(Dynamic Time Warping, DTW)[19],对所有观测指标计算患者相似性[20]。第二类是从每个个体的时间序列数据中学习一个固定长度的向量作为患者表示,然后对所有患者表示应用匹配度量,得到多组相似性得分[17]。然而,患者病史是一个长期且复杂的过程,在不同的时间表现出不同的疾病状态。目标患者的病史记录可能与另一个患者的部分病史记录相似,但很少有研究关注疾病进展的时间复杂性。本文提出的MedSim模型不仅可以从结构化时序数据中学习全面的患者表示,并且考虑时间复杂性,通过患者相似性分析以提高药物组合推荐的性能。

3 研究方法与模型

3.1 基础符号表示和问题定义

(1) 基础符号表示

在记录患者纵向病史的电子健康记录中,每位患者的医疗记录,即每次入院的诊断、手术和药物信息,可以表示为一个多变量序列,如患者i的病史记录可以表示为一系列入院医疗记录$X_i=\left[x_i^{(1)}, x_i^{(2)}, \cdots, x_i^{(T_i)}\right]$,其中$i\in\{1,2,\cdots,N\}$,$N$为数据集中所有患者的数量,$T_i$为患者$i$入院的次数。患者$i$从$x_i^{(1)}$到$x_i^{(t)}$的病史轨迹可以表示为$X_i^{1:t}$。患者$i$的第$t$次入院记录可以表示为$x_i^{(t)}=[d_i^{(t)}, p_i^{(t)}, m_i^{(t)}]$,其中$d_i^{(t)}\in\{0,1\}^{|D|}$用多维0-1向量表示诊断记录,$p_i^{(t)}\in\{0,1\}^{|P|}$表示手术记录,$m_i^{(t)}\in\{0,1\}^{|M|}$表示药物信息,$|\cdot|$表示基数,$D$、$P$、$M$分别为诊断记录集合、手术记录集合和药物集合。

(2) 问题定义

在药物组合推荐任务中,本文旨在通过目标患者i从第一次入院记录到第$t-1$次入院记录的病史轨迹$X_i^{1:t-1}$、目标患者i当前的诊断和手术记录$[d_i^{(t)}, p_i^{(t)}]$,以及相似病史序列集$\mathcal{S}_n$,学习一个药物推荐函数$f(x)$,以得到准确的药物组合$\hat{m}_i^t\in\{0,1\}^{|M|}$,如公式(1)所示。

$$\hat{m}_i^t=f\left([d_i^{(t)}, p_i^{(t)}];\ X_i^{1:t-1};\ \mathcal{S}_n\right) \tag{1}$$

药物推荐函数$f(x)$的目标由两部分组成。

①在进行药物推荐的过程中,所推荐的药物组合应尽可能与医生所开具处方一致以保证药物推荐的有效性,即使预测的$\hat{m}_i^t$尽可能接近真正的处方$m_i^t\in\{0,1\}^{|M|}$。

②在进行药物推荐的过程中,药物推荐函数应利用药物相互作用矩阵$\boldsymbol{D}$中的信息,尽可能降低药物相互作用中的拮抗作用,提高药物推荐的安全性。

本文使用的所有符号如表1所示。

表1 符号

Table1 Notation

符号	定义
$x_i^{(t)}$	第i个患者第t次入院的医疗记录
$d_i^{(t)}$	第i个患者第t次入院的诊断记录
$p_i^{(t)}$	第i个患者第t次入院的手术记录
$m_i^{(t)}$	第i个患者第t次入院的用药记录
X_i	第i个患者的全部病史记录
$X_i^{1:t}$	第i个患者从第一次到第t次入院的病史记录
$d_{ei}^{(t)}$, $p_{ei}^{(t)}$, $m_{ei}^{(t)}$	医疗记录(诊断、手术、用药)的嵌入向量
$\alpha_i^{(t)}$	第i个患者第t次入院的代码级(Code-Level)注意力
$\beta_i^{(t)}$	第i个患者第t次入院的访问级(Visit-Level)注意力
$q_i^{(t)}$	第i个患者所有病史的整合表示
$s_{i,j}^{t,k}$	患者表示$q_i^{(t)}$与$q_j^{(k)}$之间的相似性
$\mathcal{S}_n$	相似病史序列集
$\hat{m}_i^t$	第i个患者的预测药物组合
m_i^t	第i个患者的真实药物组合

3.2 MedSim模型

药物组合推荐模型MedSim的架构如图2所示,

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

包括三个模块：患者表示模块，从患者纵向病史数据中学习完整的患者表示；患者检索模块，构建患者序列存储块并量化患者轨迹之间的相似性；药物推荐模块，基于前馈神经网络预测药物组合。

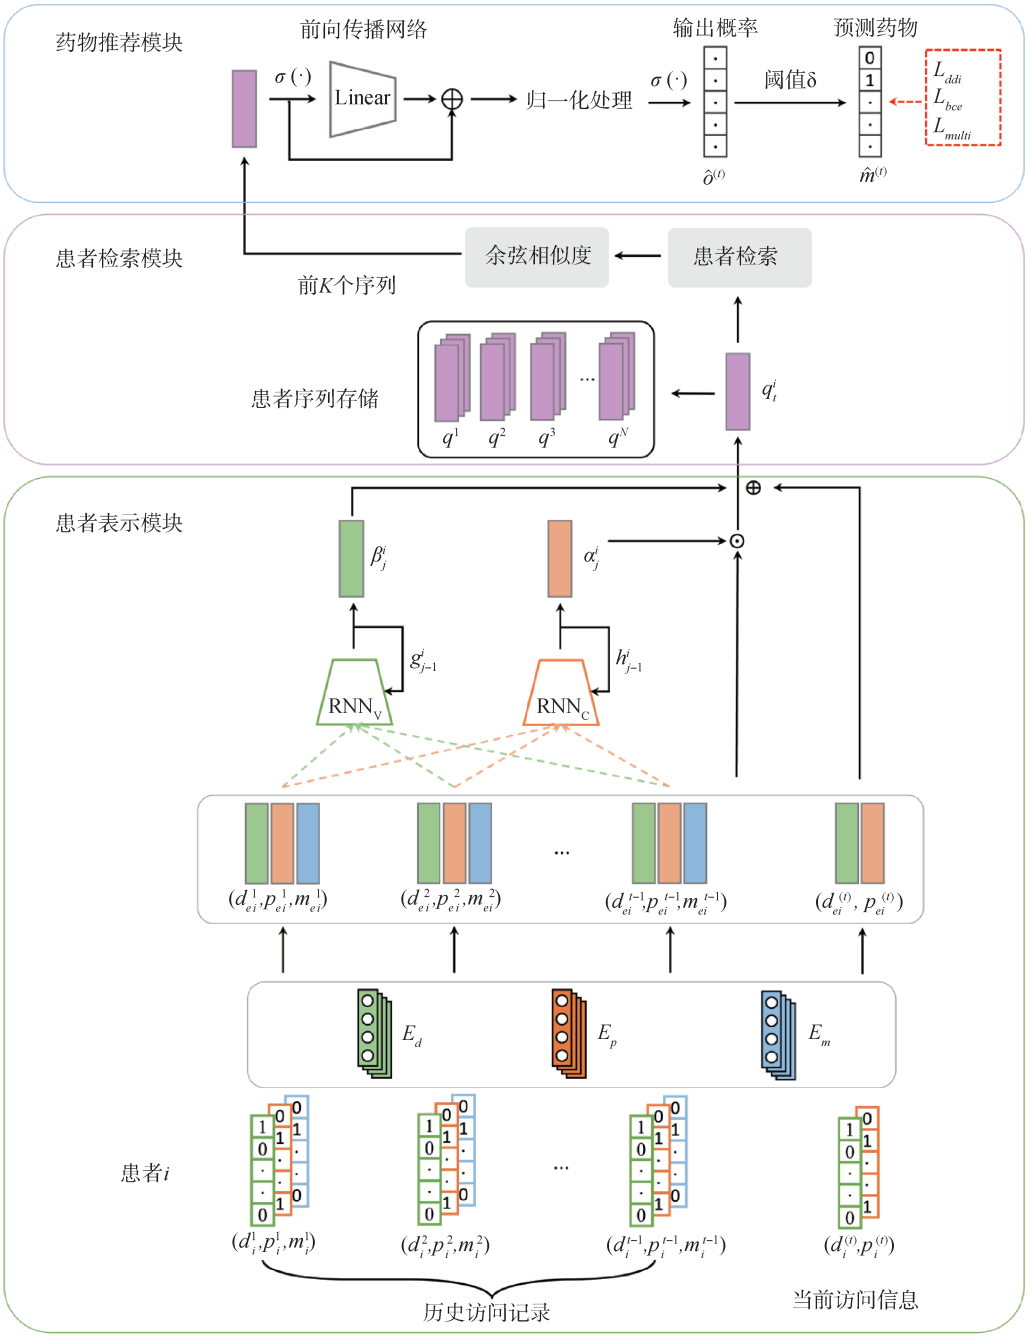


图 2　MedSim 模型架构

Fig.2　Detailed Architecture of MedSim Model

（1）患者表示模块

患者电子健康记录中的诊断记录和手术记录序列反映患者历史健康状况，是个性化药物组合推荐的关键。为了充分利用这些时序性结构化医疗信息，本文设计了一个病人编码器，它包括不同医疗信息的嵌入表（Embedding Table）和递归神经网络

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

(Recurrent Neural Networks, RNN)[21]。首先将目标患者i从第一次入院到$t-1$次入院的病史记录$X_i^{1:t-1}=[(d_i^{(1)},p_i^{(1)},m_i^{(1)}),(d_i^{(2)},p_i^{(2)},m_i^{(2)}),\cdots,(d_i^{(t-1)},p_i^{(t-1)},m_i^{(t-1)})]$和当前医疗记录$x_i^{(t)}=[d_i^{(t)},p_i^{(t)}]$映射到嵌入空间的隐层表示中,其计算流程如公式(2)-公式(4)所示。

$$d_{ei}^{(j)}=d_i^{(j)}E_d \tag{2}$$

$$p_{ei}^{(j)}=p_i^{(j)}E_p \tag{3}$$

$$m_{ei}^{(j)}=m_i^{(j)}E_m \tag{4}$$

其中,当医疗记录为诊断记录和手术记录时,$j\in\{1,2,\cdots,t\}$;医疗记录为药物记录时,$j\in\{1,2,\cdots,t-1\}$,因为需要预测患者第t次访问的用药信息。

$E_d\in\mathbb{R}^{|D|\times dim}$、$E_p\in\mathbb{R}^{|P|\times dim}$、$E_m\in\mathbb{R}^{|M|\times dim}$分别为诊断、手术和用药记录的嵌入表;$\boldsymbol{d}_{ei}^{(j)}$、$\boldsymbol{p}_{ei}^{(j)}$、$\boldsymbol{m}_{ei}^{(j)}$分别为患者$i$第$j$次入院的诊断、手术和用药记录嵌入向量。从而可以将患者i的病史记录$X_i^{1:t-1}$表示为嵌入向量$\boldsymbol{e}_i^{1:t-1}=[e_i^1,e_i^2,\cdots,e_i^{t-1}]$,将当前医疗记录$x_i^{(t)}$表示为嵌入向量$\boldsymbol{e}_i^t=[d_{ei}^{(t)},p_{ei}^{(t)}]$。

在患者的疾病轨迹中,不同的访问记录以及不同的医疗信息对于患者当前的健康状态有不同的影响。受到AMANet工作[22]利用多重注意力网络捕捉视图内及视图间关系的启发,本文考虑到病人在诊断过程中往往会以当前诊断与历史诊断的结果作为重要参考,为了更好地模拟医生诊断流程,学习患者的健康状态表示,基于上述嵌入向量表示过程,本文设计了两种不同的注意机制,即代码级注意力机制(Code-Level Attention)和访问级注意力机制(Visit-Level Attention),为患者每次入院记录中不同的医疗信息和不同的入院记录赋予不同的权重,共同构建患者的健康状态表示。

首先,为了从每次访问记录的诊断、手术及药物信息$(d_i^{(t)},p_i^{(t)},m_i^{(t)})$中学习不同医疗信息的重要程度,本文设计了代码级注意力机制,以获得每次入院记录中不同医疗信息相对应的权重$\alpha_i^{(1)},\alpha_i^{(2)},\cdots,\alpha_i^{(t-1)}$,其计算流程如公式(5)和公式(6)所示。

$$g_i^{(j)}=\mathrm{RNN}_C\left(g_i^{(j-1)},e_i^j\right) \tag{5}$$

$$\alpha_i^{(j)}=\tanh\left(\boldsymbol{W}_g g_i^{(j)}+\boldsymbol{b}_g\right) \tag{6}$$

其中,$\boldsymbol{W}_g$和$\boldsymbol{b}_g$为可学习的参数向量。

其次,为了从患者的历史入院记录$[e_i^1,e_i^2,\cdots,e_i^{t-1}]$中学习不同入院记录的重要性,本文设计了访问级注意力机制,以获得不同入院记录相对应的权重$\beta_i^{(1)},\beta_i^{(2)},\cdots,\beta_i^{(t-1)}$,其计算流程如公式(7)和公式(8)所示。

$$h_i^{(j)}=\mathrm{RNN}_V\left(h_i^{(j-1)},e_i^j\right) \tag{7}$$

$$\beta_i^{(j)}=\frac{\boldsymbol{W}_h h_i^{(j)}}{\sum_{j=1}^{t-1}\boldsymbol{W}_h h_i^{(j)}} \tag{8}$$

其中,$\boldsymbol{W}_h$为可学习的参数向量。

因此,通过结合上述两种注意力机制,可以模拟医生对患者的诊断流程,通过选择患者病史记录中相对重要的入院记录,以及患者不同入院记录中对疾病状态有影响的医疗信息,与患者的当前入院记录中诊断和手术信息相结合,可以得到患者健康状态表示。其计算流程如公式(9)所示。

$$q_i^{(t)}=e_i^t+\sum_{j=1}^{t-1}\beta_i^{(j)}\cdot(\alpha_i^{(j)}\odot e_i^j) \tag{9}$$

其中,$q_i^{(t)}$为患者i在第t次入院访问的健康状态表示;$\odot$表示元素点乘计算。

MedSim模型中的患者表示模块,通过基于初始化可学习的三种不同医疗信息(诊断、手术和药物)嵌入表和递归神经网络得到医疗记录的隐层表示;通过设计两种不同的注意力机制(代码级注意力机制和访问级注意力机制)从患者纵向病史的电子健康记录中学习完整的患者健康状态表示。与之前的研究工作GAMENet模型[14]的患者表示模块相比较,MedSim模型的改进体现在:两项工作均采用医疗信息嵌入表及递归神经网络学习不同医疗记录的隐层表示,GAMENet模型[14]仅采用患者的诊断和手术信息,采用拼接向量的方式得到最终的患者表示;而MedSim模型不仅利用诊断及手术信息,更引入患者历史用药记录,通过两种不同的注意力机制,为患者每次入院记录中不同的医疗信息和不同的入院记录赋予不同的权重,学习得到患者的健康状态表示。这种表示学习方法解决了现有工作对于患者的表征学习的不完整、未在患者表征建模的过程中考虑到历史用药对患者表征的影响以及不同访问记录之间的影响的问题。MedSim模型中新的患者表征模块学习到更为全面的患者表征,以支持下游任务,

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

有助于后续进行患者轨迹相似性计算。

（2）患者检索模块

本文将电子健康记录中的N位患者的病史记录记为$\{X_1, X_2, \cdots, X_N\}$，患者检索模块用于选择与目标患者$i$相似的若干个患者表示。

首先，构建一个患者序列存储块，用于存储目标患者的当前状态表示$q_i^{(t)}$和每个患者的病史记录信息经过患者表示模块得到的患者病史序列表示$\{q_j^{(k)}\}_{j=1,k=1}^{j=N,\ k=T_j}$。计算目标患者健康状态表示$q_i^{(t)}$与患者序列存储块中其他患者序列表示之间的余弦相似性，如公式（10）所示。

$$s_{i,j}^{t,k}=\frac{q_i^{(t)}\cdot q_j^{(k)}}{|q_i^{(t)}|\cdot|q_j^{(k)}|},\ 1\leqslant j\leqslant N,\ 1\leqslant k\leqslant T_j \tag{10}$$

其中，$s_{i,j}^{t,k}$代表患者病史序列表示$q_i^{(t)}$与$q_j^{(k)}$之间的余弦相似性。由于患者的疾病进展具有时间复杂性，目标患者的疾病状态$q_i^{(t)}$可能与患者j的某段病史序列k具有较高的相似性，因此本文计算目标患者表示与不同患者每次入院记录表示之间的相似性。只保留相似性较高的前n个病史序列构建相似病史序列集$\mathcal{S}_n$，以避免较大的计算复杂度。

MedSim模型中的患者检索模块，通过引入患者疾病轨迹的相似性计算以辅助药物推荐，这与医生的诊断流程是高度相似的。在患者来访时，医生首先根据过往该患者的病史进行判断：哪些医疗信息影响了患者现有的健康状态（可以通过患者表示模块学习得到）；其次，医生在数据库中或凭借医疗经验寻找其他相似的患者疾病轨迹，用于患者当前访问的药物组合推荐。通过患者检索模块，模型可以根据患者疾病轨迹的相似性为当前目标患者健康状态表示匹配到具有高相似性的病史序列集，有助于后续进行准确的药物推荐。

（3）药物推荐模块

在通过患者检索模块得到相似病史序列集$\mathcal{S}_n$后，本文使用患者病史序列余弦相似性$s_{i,j}^{t,k}$作为注意力权重聚合序列集$\mathcal{S}_n$中的相似患者序列，如公式（11）所示。

$$\Omega_i^{(t)}=q_i^{(t)}+\sum_{q_j^{(k)}\in\mathcal{S}_n}s_{i,j}^{t,k}\cdot q_j^{(k)} \tag{11}$$

其中，$\Omega_i^{(t)}$代表整合相似患者病史序列的当前患者表示。

为了进一步参数化$\Omega_i^{(t)}$，受到GAMENet模型[14]及残差网络（ResNet）[23]的启发，本文使用一个带有跳跃连接的多层感知机得到最终的药物组合。其计算流程如公式（12）所示。

$$o_i^{(t)}=\sigma\left(\mathrm{LN}(\Omega_i^{(t)}+\Omega_i^{(t)}\boldsymbol{W}_{LN})\right) \tag{12}$$

其中，$o_i^{(t)}$为患者i的最终药物匹配分值；$\sigma(\cdot)$为Sigmoid函数；$\boldsymbol{W}_{LN}$为可学习的参数向量，LN表示层归一化操作。最终通过将药物匹配分值$o_i^{(t)}$与预定义的阈值参数δ进行比较，可以得到本文模型推荐的最终药物组合$\hat{m}_i^t$。

（4）损失函数

MedSim模型采用端到端的训练模式，模型同时学习递归神经网络RNN_V和RNN_C中的E_d、E_p、E_m，代码级注意力机制中的参数$\boldsymbol{W}_g$和$\boldsymbol{b}_g$，访问级注意力机制中的参数$\boldsymbol{W}_h$，层归一化的参数$\boldsymbol{W}_{LN}$。

模型由三个损失函数进行训练，分别为：多标签预测损失函数L_{mp}，用于准确预测药物组合；药物相互作用损失函数L_{ddi}，用于度量预测的药物组合中药物间相互作用中的拮抗作用；可控的综合损失函数L，用于平衡各个损失之间对模型的影响程度。

① 多标签预测损失函数L_{mp}

本文将每种药物的预测作为药物组合推荐的子任务，并使用两种常见的多标签损失函数。第一个是交叉熵（Binary Cross Entropy，BCE）损失函数L_{bce}，如公式（13）所示。

$$L_{bce}=-\sum_{i=1}^{|M|}\left[m_i^{(t)}\log(o_i^{(t)})+(1-m_i^{(t)})\log(1-o_i^{(t)})\right] \tag{13}$$

其中，$m_i^{(t)}$为患者i的真实药物组合；$o_i^{(t)}$为患者i的最终药物匹配真实值。

第二个是多标签边际（Multi-label Hinge，MLH）损失L_{multi}[24]。L_{multi}确保了真实标签的预测概率至少比其他标签大一个边际，如公式（14）所示。

$$L_{multi}=\sum_{i,j:\,m_i^{(t)}=1,\,m_j^{(t)}=0}\frac{\max(0,1-(o_i^{(t)}-o_j^{(t)}))}{|M|} \tag{14}$$

多标签预测损失函数L_{mp}是通过超参数μ结合BCE损失函数L_{bce}和MLH损失函数L_{multi}制定的，如公式（15）所示。

$$L_{mp}=\mu L_{bce}+(1-\mu)L_{multi} \tag{15}$$

② 药物相互作用损失函数L_{ddi}

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

本文利用药物相互作用矩阵元素 $D_{ij}=1$ 表示药物 i 和药物 j 之间的相互作用为拮抗作用，根据药物相互作用矩阵 $\boldsymbol{D}$，药物相互作用损失函数 L_{ddi} 定义如公式(16)所示。

$$L_{ddi}=\sum_{i=1}^{|M|}\sum_{j=1}^{|M|}D_{ij}\cdot o_i^{(t)}\cdot o_j^{(t)} \tag{16}$$

③ 可控的综合损失函数 L

本文设计一个最小化联合损失训练患者表示模块和药物推荐模块的参数，具体实现步骤如公式(17)所示。

$$L=\lambda L_{mp}+(1-\lambda)L_{ddi} \tag{17}$$

其中，λ 是一个用于平衡多标签预测损失函数 L_{mp} 和药物相互作用损失函数 L_{ddi} 的超参数。为了进一步动态平衡多标签预测损失 L_{mp} 和药物相互作用损失函数 L_{ddi}，本文通过比例积分导数控制器(Proportion Integration Differentiation，PID)[25]在训练过程中调整参数 λ，调整方法如公式(18)所示。

$$\lambda=\begin{cases}1, & DDI\leqslant\gamma\\ \max\left\{0,1-\dfrac{DDI-\gamma}{K_p}\right\}, & DDI>\gamma\end{cases} \tag{18}$$

其中，K_p 为比例信号的校正因子。实验表明，γ 可以看作预测的药物组合的DDI上界。通过预设不同的阈值 γ，本文的药物推荐模型可以满足不同级别的DDI需求。

(5) 训练过程

算法1中描述了整个模型的训练算法。

算法1：MedSim模型的训练过程

输入：训练集 T，超参数 μ,λ,K_p，预定义的DDI可控阈值 γ，DDI矩阵 $\boldsymbol{D}$；

初始化参数：$E_d,E_p,E_m,\mathrm{RNN}_C,\mathrm{RNN}_V,\boldsymbol{W}_h,\boldsymbol{W}_g,\boldsymbol{b}_g,\boldsymbol{W}_{LN},LN$；

患者 i 的病史记录 $X_i^{1:t-1}$，当前访问记录 $d_i^{(t)},p_i^{(t)}$，患者序列存储块PM；

当 i 在 $[1,2,\cdots,N]$ 时：

当 j 在 $[1,2,\cdots,N]$ 时：

当 k 在 $[1,2,\cdots,T_j]$ 时：

通过公式(9)计算患者信息 $X_j^{(k)}$ 得到患者表示 $q_j^{(k)}$，添加进患者存储模块PM中；

通过公式(10)计算患者病史序列表示 $q_i^{(t)}$ 与 $q_j^{(k)}$ 之间的余弦相似性 $s_{i,j}^{t,k}$；

结束循环

结束循环

根据余弦相似性 $s_{i,j}^{t,k}$，选择前 n 个构建病史序列集 $\mathcal{S}_n$；

通过公式(11)和公式(12)计算推荐的药物组合；

通过公式(17)计算损失函数 L；

结束循环

根据公式(18)选择合适的 γ。

4 实验与结果分析

4.1 实验设置

(1) 数据集

本文将MedSim模型在MIMIC-III公开数据集[26]上进行实验，数据集包含贝斯以色列医疗中心2001-2012年曾在重症监护病房(Intensive Care Unit，ICU)的患者资料，其中涵盖了50 206份医疗记录。MIMIC-III数据集包含与大型三级护理医院重症监护病房收治的患者有关的信息。数据包括生命体征、药物、实验室测量值、医嘱、手术代码、诊断代码、住院时间、生存数据等。现有多数医疗数据挖掘研究均在MIMIC-III数据集上完成与验证。

为确保历史健康信息的可用性，在预处理过程中，选择前24小时内的药物处方，并仅将多次就诊的患者保留在数据集中。其中，诊断、手术和药物信息分别记录在病人诊断文件(DIAGNOSES_ICD.csv)、诊疗手术文件(PROCEDURE_ICD.csv)和药物处方文件(PRESCRIPTIONS.csv)三个数据表文件中。这三个文件均为结构化数据，其中未包含医嘱信息等非结构化数据。不同的表之间通过患者编号、病案号和ICU编号进行链接。在MIMIC-III数据库中，每个病人会被分配一个键值(Subject_ID)，病人每次入院记录会被分配一个键值(Adam_ID)。在预处理的过程中，首先对三个表项进行处理，将三个表项的数据按照键值Subject_ID与Adam_ID进行合并，并将其中各个表项转换为对应维数的多维0–1向量，使其满足第3节的规定形式。

本文从DrugBank数据集[27]中出现的86种DDI类型中提取前50种常见DDI类型，其中药物由DrugBank ID和PubChem ID表示。为了整合DDI数

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

据，将这两种类型的ID（DrugBank ID和PubChem ID）分别转换为Anatomical Therapeutic Chemical（ATC）3级和ATC 4级代码。然后在领域专家的帮助下，进一步将DDI分为两类：有不良反应的药物对和无反应的药物对。与之前采用的ATC 3级代码的工作相比，ATC 4级代码涵盖了更多的药物种类，可以缓解多个PubChem ID可能对应单个ATC 3级代码，以及因ATC代码不足导致的高DDI率的问题，提供了更细粒度的药物建议。该数据集的详细统计信息如表2所示。

表2　数据集统计信息

Table2　Statistics of the Dataset

项目	数量
患者	6 350
临床事件	15 031
诊断	1 958
手术	1 430
药物（ATC 3）	132
药物（ATC 4）	266
访问的平均值/总数	2.37/29
访问诊断的平均值/总数	10.51/128
访问手术的平均值/总数	3.84/50
访问药物的平均值/总数（ATC 3）	11.18/64
访问药物的平均值/总数（ATC 4）	11.87/81
DDI种类数量	50

（2）基线模型

将MedSim模型与以下基线模型进行比较，对不同指标进行评估。基线模型包括：逻辑回归（Logistic Regression，LR）、RETAIN[13]、LEAP[8]、DMNC[11]、GAMENet[14]。

①LR模型是一个基于实例的分类器，具有L2正则化。

②RETAIN模型可以使用两级RNN注意力模型提供序列预测。

③ LEAP模型是一种基于实例的方法，将药物推荐视为序列生成任务。

④DMNC模型使用记忆增强神经网络在可微分神经网络上推荐药物。LEAP模型和DMNC模型都是基于序列的模型。

⑤GAMENet模型采用记忆增强神经网络，利用图卷积神经网络对药物进行建模。DMNC模型和GAMENet模型都包含额外的领域知识数据。

（3）度量矩阵

为了衡量预测药物组合的准确性、有效性和安全性，本文使用DDI率、Jaccard相似性[28]、曲线下精确召回面积（Precision Recall Area Under Curve，PRAUC）[29]和平均F1值（F1）进行计算。评估指标的详细定义如下。

患者 i 的DDI率计算如公式（19）所示。

$$DDI_i = \frac{\sum_{t=1}^{T_i}\sum_{k,l\in\{\hat{m}_{i,j}^{(t)}=1\}} 1\{D_{kl}=1\}}{\sum_{t=1}^{T_i}\sum_{k,l\in\{\hat{m}_{i,j}^{(t)}=1\}} 1} \tag{19}$$

其中，T_i 表示患者 i 总共的访问次数；$\hat{m}_{i,j}^{(t)}$ 表示患者 i 的预测药物组合向量中的第 j 个元素。

Jaccard相似性定义为交集的大小除以并集的大小，如公式（20）所示。

$$Jaccard_i = \frac{1}{T_i}\sum_{t=1}^{T_i}\frac{|\{m_{i,j}^{(t)}=1\}\cap\{\hat{m}_{i,j}^{(t)}=1\}|}{|\{m_{i,j}^{(t)}=1\}\cup\{\hat{m}_{i,j}^{(t)}=1\}|} \tag{20}$$

F1值定义如公式（21）-公式（23）所示。

$$P_i^{(t)} = \frac{|\{m_{i,j}^{(t)}=1\}\cap\{\hat{m}_{i,j}^{(t)}=1\}|}{|\{\hat{m}_{i,j}^{(t)}=1\}|} \tag{21}$$

$$R_i^{(t)} = \frac{|\{m_{i,j}^{(t)}=1\}\cap\{\hat{m}_{i,j}^{(t)}=1\}|}{|\{m_{i,j}^{(t)}=1\}|} \tag{22}$$

$$F1_i = \frac{1}{T_i}\sum_{t=1}^{T_i}\frac{2P_i^{(t)}R_i^{(t)}}{P_i^{(t)}+R_i^{(t)}} \tag{23}$$

PRAUC定义如公式（24）所示。

$$PRAUC_i = \frac{1}{T_i}\sum_{t=1}^{T_i}\sum_{k=1}^{|M|}P(k)_i^{(t)}(R(k)_i^{(t)} - R(k-1)_i^{(t)}) \tag{24}$$

其中，k 为检索到的药物序列中的排名。

（4）模型补充细节

与之前的工作相同，将数据集按照4∶1∶1划分为训练集、验证集和测试集。本文使用PyTorch 1.6.0和Python 3.7.5实现MedSim模型和所有基线模型。所有模型都在4个NVIDIA Tesla V100 GPU上进行训练。在模型中，E_d、E_p、E_m 的维度以及 RNN_C、RNN_V 中隐藏层的大小设置为64。L_{MP} 损失中的权重 μ 设置为0.95，控制参数 γ 设置为0.06。本文实验中的所有模型都由Adam优化器优化；使用 2×10^{-4} 的学习率在50个Epoch内训练模型。所有基线模型都使用参考文献中的优化参数进行训练。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

4.2 实验结果

（1）性能比较

模型性能对比如表3所示。对所有模型进行10轮测试，报告其不同度量分数的平均值和标准差。从表3中可以看出，相比于其余基线模型，LEAP、DMNC这两种序列生成模型产生的结果较差，这说明用多标签预测药物组合更直接和有效。通过比较表3中不同药品代码（ATC3和ATC4）之间模型的结果差异，随着药品数量的增加（从ATC3到ATC4），各度量指标（Jaccard相似性、PRAUC和F1值）相对应减小。与不使用任何DDI知识的模型（LR和RETAIN）和利用外部DDI知识的模型（LEAP、DMNC和GAMENet）相比，MedSim模型同时实现了最低的DDI率和更高的Jaccard相似性、PRAUC和F1值，即更高的准确性。MedSim模型在DDI率方面表现优于使用患者病史的GAMENet模型和其他所有基线模型。MedSim模型没有引入外部的药物知识，只是在损失函数对DDI进行约束，这表明利用患者病史序列相似性分析以解决药物组合推荐问题在用药安全方面是有效的。

表3 模型性能对比

Table3 Performance Comparison

代码	模型	DDI率	Jaccard相似性	F1值	PRAUC	药物平均数量
ATC3	LR	0.088 1±0.000 8	0.496 6±0.002 8	0.633 5±0.002 4	0.730 0±0.003 2	15.990 4±0.099 0
	RETAIN	0.093 3±0.001 5	0.497 8±0.002 8	0.637 2±0.002 5	0.748 3±0.003 0	18.742 4±0.073 8
	LEAP	0.094 5±0.000 4	0.480 4±0.002 6	0.621 8±0.002 6	0.746 3±0.003 0	18.742 4±0.073 8
	DMNC	0.088 1±0.000 4	0.495 4±0.002 0	0.637 3±0.002 7	0.735 9±0.003 8	20.000 0±0.000 0
	GAMENet	0.087 9±0.000 7	0.499 5±0.002 3	0.643 8±0.002 3	0.749 1±0.002 6	20.793 9±0.062 8
	MedSim	**0.076 1±0.000 9**	**0.511 8±0.002 3**	**0.657 9±0.002 3**	**0.756 3±0.003 0**	17.456 0±0.068 6
ATC4	LR	0.089 5±0.000 7	0.382 6±0.002 4	0.531 3±0.002 3	0.627 1±0.001 7	14.332 5±0.112 8
	RETAIN	0.099 2±0.001 7	0.392 0±0.003 7	0.553 5±0.004 1	0.622 7±0.004 7	16.631 9±0.163 2
	LEAP	0.109 0±0.001 0	0.382 1±0.002 9	0.531 8±0.003 4	0.594 3±0.005 2	18.998 1±0.060 4
	DMNC	0.103 6±0.000 4	0.394 3±0.002 1	0.543 4±0.002 3	0.619 4±0.003 0	20.000 0±0.000 0
	GAMENet	0.079 4±0.000 8	0.391 7±0.003 6	0.552 5±0.003 8	0.618 3±0.004 1	19.349 1±0.104 1
	MedSim	**0.068 5±0.000 3**	**0.415 5±0.002 4**	**0.566 5±0.002 4**	**0.629 1±0.002 8**	20.076 4±0.083 3

（2）可控的DDI分析

评估模型DDI的可控性，实验结果表明MedSim模型的平均DDI率可以由阈值γ控制。经过计算，MIMIC-III数据集的真实DDI率为0.089 1。本文认为基于深度学习的药物推荐模型应该输出低于医学专家给出的药物推荐建议的DDI率。本文测试了一系列从0到0.08的目标DDI阈值γ。对于每个γ，对测试集进行10轮测试，并报告其平均值和标准差，如表4所示。从结果来看，在大多数情况下，DDI率被γ控制和限制，这与设计一致。当γ变大时，允许更多的药物，安全药物更准确。当γ变小时，模型精度将显著下降。参数γ提供了一种控制DDI率和准确性之间的权衡的方法。

（3）候选集大小分析

在模型中至关重要的是由不同的前n个高相似性的病史序列构建的相似病史序列集$\mathcal{S}_n$，本文评估了不同的n值及不同的序列集大小对于模型结果的影响，如表5所示。可以看到，候选集的大小对于模型的影响并不是很大，随着候选集的增多，更多具有弱相似性的患者轨迹被纳入候选集中，经过相似性归一化后，弱相似性患者表示的权重变得很小，由于强相似性的患者表示具有较大的权重，因此候选集的增加并不会对患者的最终表示产生较大的影响，同时也不会对模型的效果产生显著的影响。

（4）用例分析

本文提供了用例分析进一步证明MedSim模型的有效性与安全性。从MIMIC-III数据集中选择两个患者，分别使用MedSim、LEAP和GAMENet三种模型根据他们的历史病历预测药物组合，如表6所示。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

表4　不同DDI率γ下的模型性能

Table4　Performance Under Acceptance DDI Rate γ

γ	DDI率	Jaccard相似性	F1值	PRAUC	药物平均数量
0.00	0.010 8±0.000 3	0.409 7±0.002 1	0.560 2±0.002 3	0.612 0±0.002 9	19.059 9±0.057 9
0.01	0.022 5±0.000 4	0.409 9±0.002 6	0.561 1±0.002 6	0.610 9±0.002 5	19.140 3±0.079 7
0.02	0.024 3±0.000 3	0.411 0±0.002 2	0.561 7±0.002 2	0.617 9±0.002 5	19.114 6±0.093 1
0.03	0.037 0±0.000 2	0.413 1±0.002 2	0.564 2±0.002 3	0.622 1±0.002 5	19.352 0±0.113 7
0.04	0.040 7±0.000 3	0.413 6±0.001 8	0.565 0±0.001 8	0.627 9±0.002 2	19.827 2±0.105 8
0.05	0.054 4±0.000 2	0.414 5±0.001 9	0.566 1±0.001 9	0.628 0±0.002 8	20.165 8±0.090 5
0.06	0.068 5±0.000 3	0.415 5±0.002 4	0.566 5±0.002 4	0.629 1±0.002 8	20.076 4±0.083 3
0.07	0.074 4±0.000 4	0.418 0±0.002 2	0.568 7±0.002 1	0.633 3±0.002 3	20.555 7±0.098 2
0.08	0.081 5±0.000 4	0.419 3±0.002 8	0.590 3±0.002 8	0.636 4±0.002 6	20.890 8±0.120 7

表5　不同大小的候选集的模型性能

Table5　Performance Under Different Candidate Set

n	DDI率	Jaccard相似性	F1值	PRAUC	药物平均数量
6	0.066 2±0.000 3	0.408 1±0.002 1	0.559 6±0.002 2	0.624 0±0.002 3	20.585 3±0.105 0
8	0.067 0±0.000 3	0.415 3±0.002 3	0.566 1±0.002 4	0.628 7±0.002 9	19.214 6±0.063 6
10	0.068 5±0.000 3	0.415 5±0.002 4	0.566 5±0.002 4	0.629 1±0.002 8	20.076 4±0.083 3
12	0.067 7±0.000 4	0.414 2±0.002 1	0.565 2±0.002 1	0.628 1±0.002 3	19.351 8±0.113 8
14	0.067 9±0.000 3	0.414 0±0.002 6	0.564 5±0.002 6	0.627 3±0.003 0	18.045 1±0.058 8

表6　用例分析

Table6　Cases Studies

病例	模型	DDI率	药物组合推荐
病例1	处方	0.126 3	A01AD，A02BA，B05CX，C01CA，M01AB，N01AX，C07AB，N02BE，C03CA，N07AA，A02BC，C10AA，A06AD，A12BA，J01DB，C01DA，A01AB，A03FA，A02AA，N06A
	LEAP	0.105 2	**15 正确**：A01AD，A02BA，B05CX，C01CA，M01AB，N01AX，C07AB，N02BE，C03CA，N07AA，A02BC，C10AA，A06AD，A12BA，J01DB 6 错误：A07AA，A02BX，N02AA，B01AB，**C01BD(2)**，J01DH
	GAMENet	0.090 8	**17 正确**：A01AD，A02BA，B05CX，C01CA，M01AB，N01AX，C07AB，N02BE，C03CA，N07AA，A02BC，C10AA，A06AD，A12BA，J01DB，C01DA，A03FA 6 错误：A07AA，A02BX，N02AA，B01AB，H03AA，J01DH
	MedSim	0.087 1	**19 正确**：A01AD，A02BA，B05CX，C01CA，M01AB，N01AX，C07AB，N02BE，C03CA，N07AA，A02BC，C10AA，A06AD，A12BA，J01DB，A01AB，A03FA，A02AA，N06AX 1 错误：A02B
病例2	处方	0.097 7	A07AA，N01AX，N02BE，B05CX，N03AX，A06AD，A12BA，A01AB，B03BB，N07BA，A04AA，C01EB，D04AA，J01DD，N05CF，A01A
	LEAP	0.085 7	**8 正确**：A07AA，B05CX，N03AX，A06AD，A12BA，A01AB，B03BB，N07BA 7 错误：**A01AD(1)**，A02BA，N02AA，B01AB，C02DB，A02BC，**N03AB(2)**
	GAMENet	0.079 2	**8 正确**：A07AA，B05CX，N03AX，A06AD，A12BA，A01AB，B03BB，N07BA 7 错误：**A01AD(1)**，A02BA，N02AA，B01AB，C02DB，**R06AX(1)**，J01XX
	MedSim	0.076 1	**8 正确**：A07AA，N02BE，B05CX，N03AX，A06AD，A12BA，B03BB，A04AA 6 错误：A02BA，N02AA，N06AX，B01AB，**N05BA(1)**，A02BC

其中“正确”表示预测的药物与医生开具的处方是相同的；“错误”表示预测的药物是医生开具的处方中没有出现的；“药物名称(n)”表明这种错误预测的药物与正确预测的药物间具有n种互为拮抗作用

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

的药物反应类型。在病例1的模型预测结果中，只有MedSim模型能够准确预测出现在处方中的正确药物。相比之下，GAMENet和LEAP模型未能做出准确的预测。在病例2中，所有模型都未能给出完全准确的药物组合建议。本文分析了每个模型预测错误的药物和预测正确的药物之间互为拮抗反应对的个数以及预测的药物组合的DDI率。值得注意的是，与其他模型相比，MedSim模型预测错误的药物与预测正确的药物具有更少拮抗作用，同时MedSim模型预测的药物组合具有更低的DDI率，展现了模型对DDI提供了很好的约束。结合其他模型的实验结果，该用例分析研究进一步验证了MedSim模型的有效性与安全性。

5 结 语

本文提出了一种新的药物推荐深度学习模型MedSim，该模型通过整合患者结构化多变量时序数据学习到完整的患者表示，并通过检索和目标患者相似的序列，以推荐安全有效的药物组合，通过结合患者相似性分析提高药物预测性能。通过在公开数据集MIMIC-III上进行实验，证明了MedSim模型的有效性和安全性。MedSim模型在准确预测药物组合方面取得了优于其他基线模型的性能，同时所预测的药物组合实现了较低的DDI率。MedSim模型可以预测比现有方法更安全、更准确的药物组合。

本文围绕电子病历数据相关的临床任务，面向药物组合预测和患者表征学习方法中面临的一系列挑战，旨在提高用药推荐算法的准确率与安全性。当前工作具有以下两方面局限性：一方面，模型尚未融入生物医学等具有领域特色的先验知识；另一方面，在研究中发现数据集中存在一些不可避免的错误用药信息，而现有工作未深究数据本身存在的噪声对模型的影响，以及在临床应用时可能出现的问题。在未来工作中将进一步针对上述局限性展开研究，以最大程度地向“精准医疗”和“个性化医疗”的目标迈近。

参考文献：

[1] Lee C, Luo Z J, Ngiam K Y, et al. Big Healthcare Data Analytics: Challenges and Applications [A]//Handbook of Large-Scale Distributed Computing in Smart Healthcare[M]. Berlin: Springer, 2017: 11-41.

[2] Miotto R, Wang F, Wang S, et al. Deep Learning for Healthcare: Review, Opportunities and Challenges[J]. Briefings in Bioinformatics, 2018, 19(6): 1236-1246.

[3] Choi E, Bahadori M T, Schuetz A, et al. Doctor AI: Predicting Clinical Events via Recurrent Neural Networks[C]//Proceedings of the Machine Learning for Healthcare 2016. 2016: 301-318.

[4] Xiao C, Choi E, Sun J M. Opportunities and Challenges in Developing Deep Learning Models Using Electronic Health Records Data: A Systematic Review[J]. Journal of the American Medical Informatics Association, 2018, 25(10): 1419-1428.

[5] 国务院办公厅. 国务院办公厅关于促进和规范健康医疗大数据应用发展的指导意见[J]. 中华人民共和国国务院公报,2016(19):24-28.(General Office of the State Council of the People's Republic of China. Guidance on Promoting and Regulating the Development of Health Care Big Data Applications[J]. ZHONGHUA RENMIN GONGHEGUO GUOWUYUAN GONGBAO, 2016(19):24-28.)

[6] Panagioti M, Stokes J, Esmail A, et al. Multimorbidity and Patient Safety Incidents in Primary Care: A Systematic Review and Meta-Analysis[J]. PLoS One, 2015, 10(8): e0135947.

[7] Vinyals O, Bengio S, Kudlur M. Order Matters: Sequence to Sequence for Sets[OL]. arXiv Preprint, arXiv:1511.06391.

[8] Zhang Y T, Chen R, Tang J, et al. LEAP: Learning to Prescribe Effective and Safe Treatment Combinations for Multimorbidity [C]//Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2017: 1315-1324.

[9] Gong F, Wang M, Wang H F, et al. SMR: Medical Knowledge Graph Embedding for Safe Medicine Recommendation[J]. Big Data Research, 2021, 23: 100174.

[10] Zheng Z, Wang C, Xu T, et al. Drug Package Recommendation via Interaction-Aware Graph Induction[C]//Proceedings of the Web Conference. 2021:1284-1295.

[11] Le H, Tran T, Venkatesh S. Dual Memory Neural Computer for Asynchronous Two-View Sequential Learning[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2018: 1637-1645.

[12] Shang J Y, Ma T F, Xiao C, et al. Pre-training of Graph Augmented Transformers for Medication Recommendation[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence. 2019: 5953-5959.

[13] Choi E, Bahadori M T, Kulas J A, et al. RETAIN: An Interpretable Predictive Model for Healthcare Using Reverse Time Attention Mechanism[C]//Proceedings of the 30th International Conference on Neural Information Processing Systems. 2016: 3512-3520.

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[14] Shang J Y, Xiao C, Ma T F, et al. GAMENet: Graph Augmented Memory Networks for Recommending Medication Combination [C]//Proceedings of the AAAI Conference on Artificial Intelligence. 2019, 33: 1126-1133.

[15] Wang S S, Ren P J, Chen Z M, et al. Order-Free Medicine Combination Prediction with Graph Convolutional Reinforcement Learning[C]//Proceedings of the 28th ACM International Conference on Information and Knowledge Management. 2019: 1623-1632.

[16] Sun J M, Wang F, Hu J Y, et al. Supervised Patient Similarity Measure of Heterogeneous Patient Records[J]. ACM SIGKDD Explorations Newsletter, 2012, 14(1): 16-24.

[17] Suo Q L, Ma F L, Yuan Y, et al. Personalized Disease Prediction Using a CNN-Based Similarity Learning Method[C]// Proceedings of the 2017 IEEE International Conference on Bioinformatics and Biomedicine. 2017: 811-816.

[18] Zhang P, Wang F, Hu J Y, et al. Towards Personalized Medicine: Leveraging Patient Similarity and Drug Similarity Analytics[J]. AMIA Joint Summits on Translational Science.2014：132-136.

[19] Müller M. Dynamic Time Warping[A]//Information Retrieval for Music and Motion[M]. Berlin: Springer, 2007: 69-84.

[20] Yin C C, Liu R Q, Zhang D D, et al. Identifying Sepsis Subphenotypes via Time-Aware Multi-modal Auto-encoder[C]// Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 862-872.

[21] Chung J, Gulcehre C, Cho K, et al. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling[OL]. arXiv Preprint, arXiv:1412.3555.

[22] He Y, Wang C, Li N, et al. Attention and Memory-Augmented Networks for Dual-View Sequential Learning[C]//Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. 2020: 125-134.

[23] He K M, Zhang X Y, Ren S Q, et al. Deep Residual Learning for Image Recognition[C]//Proceedings of the 2016 IEEE Conference on Computer Vision and Pattern Recognition. 2016: 770-778.

[24] Ji S W, Ye J P. Linear Dimensionality Reduction for Multi-label Classification[C]//Proceedings of the 21st International Joint Conference on Artificial Intelligence. 2009: 1077-1082.

[25] An W P, Wang H Q, Sun Q Y, et al. A PID Controller Approach for Stochastic Optimization of Deep Networks[C]//Proceedings of the 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2018: 8522-8531.

[26] Johnson A E W, Pollard T J, Shen L, et al. MIMIC-III, a Freely Accessible Critical Care Database[J]. Scientific Data, 2016, 3: 160035.

[27] Wishart D S, Feunang Y D, Guo A C, et al. DrugBank 5.0: A Major Update to the DrugBank Database for 2018[J]. Nucleic Acids Research, 2018, 46(D1): D1074-D1082.

[28] Niwattanakul S, Singthongchai J, Naenudorn E, et al. Using of Jaccard Coefficient for Keywords Similarity[C]//Proceedings of the 2013 IAENG International Conference on Internet Computing and Web Services. 2013.

[29] Davis J, Goadrich M. The Relationship Between Precision-Recall and ROC Curves[C]//Proceedings of the 23rd International Conference on Machine Learning. 2006: 233-240.

作者贡献声明：

吴佳伦：设计研究方案，进行实验，论文起草和修订；
张若楠：提出研究思路，文献调研，清洗和分析实验数据，论文修改；
康武林：整合研究思路，实验数据预处理；
袁普卫：明确研究路线，论文最终版本修订。

利益冲突声明：

所有作者声明不存在利益冲突关系。

支撑数据：

支撑数据由作者自存储, E-mail: jialunwu96@stu.xjtu.edu.cn。
[1]吴佳伦，张若楠 . MedSim 模型数据及代码 . DOI: 10.57760/sciencedb.j00133.00061.

收稿日期：2022-05-25
收修改稿日期：2022-07-19

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Deep Learning Model of Drug Recommendation Based on Patient Similarity Analysis

Wu Jialun[1] Zhang Ruonan[2] Kang Wulin[3] Yuan Puwei[3]

[1](School of Computer Science and Technology, Xi'an Jiaotong University, Xi'an 710049, China)

[2](Library of Xi'an Jiaotong University, Xi'an 710049, China)

[3](Affiliated Hospital of Shaanxi University of Chinese Medicine, Xianyang 712046, China)

Abstract: [**Objective**] This paper develops a deep learning model that accurately predicts drug combinations by analyzing structured time-series medical data and patient similarity. [**Methods**] Our model learned comprehensive patient representations by parsing structured time-series data through two attention mechanisms. Then, we calculated the patients' similarity to enrich their representation and transformed the drug recommendation problem into a multi-label learning task. [**Results**] We examined the new model with the MIMIC-III dataset. Compared to other mainstream models, the proposed one achieved improvements of at least 1.09%, 2.38%, 1.40%, and 1.08% in DDI rate, Jaccard similarity, PRAUC, and F1-score, respectively. [**Limitations**] Our model should have included the prior domain knowledge from biomedical fields. More research is needed to thoroughly investigate the noise in the data and potential issues in clinical applications. [**Conclusions**] The proposed method can learn comprehensive patient representations and enhance the safety and accuracy of drug recommendation tasks.

Keywords: Drug Recommendation Electronic Health Records Patient Representation Learning Deep Learning

研究表明用户不了解他们的手机中可能正在共享的数据

英国巴斯大学管理学院的最新研究显示,智能手机中的隐私和安全功能旨在让消费者对智能手机应用程序共享数据有更多控制权,但这一功能被用户广泛误解。研究显示,43%的手机用户对应用程序跟踪的含义感到困惑或不清楚。人们通常误解了应用程序跟踪的目的,误认为是应用程序的固有功能,或是会提供更好的用户体验。而实际上应用程序跟踪的目的是向智能手机用户提供有针对性的广告。如果用户选择不允许跟踪,将无法再跟踪用户在设备上使用应用程序和网站的情况,这些数据也无法用于定向广告或是数据共享。

研究人员共收集了312名参与者(年龄在18~75岁)的跟踪决策数据,并分析了他们允许或拒绝一系列应用程序跟踪的原因,包括社交媒体、购物、健康和食品配送等各类应用程序。研究人员指出:"人们对应用程序跟踪的含义存在重大误解。人们普遍认为,需要允许跟踪应用程序才能正常运行。最常见的误解(24%)是,跟踪指的是共享设备的物理位置,而不是跟踪应用程序和网站的使用情况。"造成这种混乱和误解的部分原因可能是由于相关公司在跟踪提示中使用的措辞不够清晰、明确。

研究人员说:"每天都有数百万人与科技公司共享信息,虽然其中一些数据对这些服务的正常运行至关重要,但其他数据却能够使这些科技公司从广告中获取利润。我们还需要做更多的工作,这样人们才能对数字时代数据的用途做出透明的决定。"

(编译自:https://www.sciencedaily.com/releases/2023/05/230509122057.htm)

(本刊讯)

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net